

Recomendação de Objetos de Aprendizagem Empregando Filtragem Colaborativa e Competências

Sílvia César Cazella¹, Eliseo Berni Reategui², Munique Machado¹, Jorge Luis V. Barbosa¹

¹Universidade do Vale do Rio dos Sinos (UNISINOS)
Av. Unisinos, 950, CEP 93022-001, São Leopoldo, RS - Brasil

² Universidade Federal do Rio Grande do Sul
Av. Paulo Gama 110, prédio 12105, Porto Alegre, RS, Brazil

{cazella, jbarbosa}@unisinos.br, muniquem.machado@gmail.com,
eliseoreategui@gmail.com

Abstract. *This paper presents a model for a learning objects recommender system based on collaborative filtering and competencies. The model enables students to receive recommendations of learning objects automatically, according to students' interests but also according to competencies that have to be developed. The prototype implemented was able to recommend relevant contents to students, aiming at helping them in the development of competencies. At the end of this paper, a couple of experiments are presented as well as results achieved and ideas for future work.*

Resumo. *Este artigo apresenta um modelo de sistema de recomendação de objetos de aprendizagem baseado em Filtragem Colaborativa e competências. O modelo permite que alunos recebam a recomendação de objetos de aprendizagem de forma automática conforme interesses do aluno, e de acordo com as competências que devem ser desenvolvidas dentro de um plano de aula. O protótipo implementado permitiu recomendar conteúdo relevante para os alunos com o intuito de auxiliá-los no processo de desenvolvimento destas competências. No final deste artigo são descritos alguns experimentos realizados e os resultados promissores obtidos com a aplicação do modelo proposto, bem como trabalhos futuros.*

Palavras Chave: *Sistemas de Recomendação, Filtragem Colaborativa, Competências*

1. Introdução

Um desafio importante com o qual todo educador se depara é a organização de conteúdos e atividades voltados ao desenvolvimento de determinadas competências. Este desafio é intensificado quando se busca identificar e recomendar materiais distintos, personalizados para cada aluno, com base em necessidades individuais, interesses e competências a serem desenvolvidas.

Este artigo propõe um sistema computacional para fazer a recomendação personalizada de objetos de aprendizagem (OA), de acordo com as predileções (“gostos” por determinados objetos de aprendizagem) de cada aluno, bem como em competências a serem desenvolvidas. Objetos de aprendizagem são compreendidos aqui como materiais educacionais digitais desenvolvidos de forma modular de maneira que possam ser utilizados separadamente, bem como em conjunto – sendo baseados no

paradigma orientado a objeto [Wiley 2000]. Neste sentido, um artigo científico, uma página web, um simulador, um programa de perguntas e respostas programadas, todos são considerados aqui objetos de aprendizagem.

O foco na recomendação de objetos de aprendizagem voltados ao desenvolvimento de competências exige uma mudança de paradigma educacional, desprendendo-se de modelos pedagógicos fundamentados em currículos rígidos e metodologias transmissivas centradas no ensino. Volta-se então para modelos pedagógicos mais flexíveis com foco no desenvolvimento de competências, respeitando características sociais, interesses, necessidades e limitações de cada indivíduo. Entende-se o conceito de competência como a inteligência prática para situações que se apóiam sobre conhecimentos adquiridos e os mobilizam, transformando-os de acordo com a complexidade das situações [Zarifian 2002]. Neste sentido, conhecimentos (saberes) e habilidades (saber fazer, ou *know-how*) fazem parte do conceito de competência [Fleury and Fleury 2000]. Embora a recomendação personalizada de OA seja uma característica desejável em qualquer sistema computacional voltado à educação, independente da área do conhecimento, nosso foco de estudo são os currículos dos cursos de graduação nas áreas de Tecnologia da Informação (Ciência da Computação, Engenharia da Computação, Sistemas de Informação, Licenciatura em Computação). Estes apresentam uma série de disciplinas que são distribuídas ao longo dos semestres de acordo com um conjunto de pré-requisitos. As ementas destas disciplinas geralmente elencam uma série de competências que os alunos deverão desenvolver. Por exemplo, em um currículo de Engenharia da Computação, uma disciplina de Banco de Dados pode exigir que o aluno desenvolva competência em “*Modelagem Multidimensional*”. É com base nesta organização de competências que se fundamenta este trabalho. Busca-se através deste projeto facilitar o acesso do aluno aos objetos de aprendizagem mais apropriados em determinados momentos de acordo com características próprias dos alunos, bem como de acordo com competências que precisam ser desenvolvidas, e distribuídas em um plano de aulas.

Dentre as técnicas computacionais destinadas a auxiliar na busca de informações relevantes, destacam-se os Sistemas de Recomendação [Adomavicius and Tuzhilin 2005], capazes de identificar automaticamente conteúdos apropriados para cada indivíduo com base em suas características ou “gostos”. Este artigo descreve um modelo para sistemas de recomendação que possibilita recomendar objetos de aprendizagem relevantes a alunos de graduação, focando nas competências a serem desenvolvidas nas disciplinas. A principal contribuição deste artigo é apresentar este modelo bem como sua aplicação e avaliação junto a uma turma da graduação.

Este artigo está estruturado da seguinte forma: a seção 2 estende a discussão sobre o conceito de competência, enfatizando suas implicações no desenvolvimento de um sistema de recomendação; a seção 3 apresentada a técnica de Filtragem Colaborativa aplicada a sistemas de recomendação; a seção 4 descreve em detalhes o modelo proposto, bem como prototipação e experimentos realizados, e resultados obtidos; a seção 5 apresenta conclusões e propostas para trabalhos futuros.

2. O Conceito de Competência

É possível encontrar na literatura várias definições para o conceito de competência. Do dicionário Aurélio da Língua Portuguesa, obtém-se a seguinte definição: “*Qualidade de quem é capaz de apreciar e resolver certo assunto, fazer determinada coisa;*

capacidade, habilidade, aptidão, idoneidade”. Nesta definição, contudo, não ficam explícitas as relações entre os conceitos mencionados (ex.: habilidades, assuntos, conhecimentos). Outros autores aprimoram a definição: competência pode ser definida como sendo o conjunto de conhecimentos, habilidades e atitudes necessárias para que a pessoa desenvolva suas atribuições e responsabilidades [Dutra 2001]. Já [Perrenoud 1999] define competência como a faculdade de mobilizar um conjunto de recursos cognitivos (saberes, capacidades, informações, etc.) para solucionar com pertinência e eficácia uma série de situações. Desta forma as competências estão ligadas a contextos culturais, profissionais e condições sociais.

Em todas as definições, percebe-se o relacionamento do conceito de competência com habilidades (saber fazer), conhecimentos (saberes) e atitudes (quando fazer). No contexto desta pesquisa, portanto, a questão que se coloca é como, quando e de que forma podemos fazer a recomendação de objetos de aprendizagem que possibilitem aos estudantes: construir conhecimento relacionado a determinados assuntos; desenvolver habilidades precisas relacionadas aos conteúdos tratados; desenvolver nos alunos uma consciência crítica com relação à importância desta competência para que compreendam como e quando utilizá-la.

A proposta para endereçar as questões acima é empregar um sistema de recomendação para filtrar informações relevantes para o estudante e a partir destas selecionar objetos de aprendizagem mais apropriados de acordo com as competências a serem desenvolvidas. A próxima seção apresenta o conceito de sistemas de recomendação.

3. Sistemas de Recomendação

Existem várias aplicações de recuperação de conteúdo que buscam auxiliar os usuários na identificação de itens de interesse. Porém, é comum que estas aplicações tragam muito conteúdo irrelevante [Adomavicius and Tuzhilin 2005]. Buscando minimizar este problema, os sistemas de recomendação surgiram, focando na busca por informações relevantes de acordo com características do próprio usuário, bem como em determinados requisitos relacionados aos itens que se quer encontrar.

Diferentes técnicas são aplicadas nos sistemas de recomendação para que os conteúdos mais adequados para seus usuários sejam encontrados. Em [Sarwar et al. 2000], por exemplo, diferentes algoritmos de recomendação são comparados quanto ao sua precisão e desempenho. Aqui, nosso foco é a técnica de Filtragem Colaborativa (FC) [Shardanand and Maes 1995], uma técnica que se baseia nas informações coletadas sobre toda a comunidade de usuários e que já se mostrou adequada às mais variadas aplicações [Herlocker et al. 2004].

3.1. Filtragem Colaborativa

A Filtragem Colaborativa constitui-se em uma das mais populares técnicas de recomendação, sendo utilizada em muitos sistemas existentes na Internet [Schafer et al. 2001]. A técnica se baseia na análise de preferências comuns em um grupo de pessoas. A essência desta técnica está na troca de experiências entre as pessoas que possuem interesses comuns e possuem “gostos” semelhantes por itens.

Nesta técnica, os conteúdos que podem ser recomendados são filtrados com base nas avaliações (*feedback*) feitas pelos usuários sobre os mesmos itens. Esta avaliação

procura observar o comportamento de um grupo e analisar as similaridades entre os “gostos” pelos itens dentro do grupo. Para cada usuário procura-se identificar um conjunto de “vizinhos próximos”, que são assim classificados por possuírem um comportamento semelhante [Adomavicius and Tuzhilin 2005]. As próximas subseções tratam do cálculo do coeficiente de similaridade entre dois usuários, etapa preliminar de um processo de Filtragem Colaborativa, e da seleção dos subconjuntos de usuários com maiores similaridades, denominados vizinhos, que serão considerados na etapa de predição. Nesta última etapa, predições são calculadas para indicar o quão apropriado é um item para determinado usuário.

3.1.1 Cálculo do Coeficiente de Similaridade e Cálculo da Predição

Para o cálculo da similaridade entre alunos, o modelo proposto neste artigo adotou o coeficiente de Pearson, sendo esta uma abordagem amplamente utilizada na área de Sistemas de Recomendação baseados em Filtragem Colaborativa [Shardanand and Maes 1995]. Este coeficiente permite medir o grau de correlação entre duas variáveis, resultando em valores entre $[-1; +1]$, onde o valor -1 representa ausência total de correlação entre as variáveis, e o valor $+1$ representa forte correlação entre as mesmas.

Uma vez que se obtenha a correlação entre as opiniões de alunos sobre determinados objetos de aprendizagem, pode-se calcular a recomendação de um objeto com base em uma predição de quanto o aluno apreciaria receber determinada recomendação (predição refere-se a prever qual a nota que este aluno daria ao objeto, caso tivesse acesso ao mesmo).

O cálculo da predição é realizado independentemente do coeficiente utilizado no cálculo da similaridade, uma vez que este cálculo é realizado com base em uma média ponderada das avaliações fornecidas pelos alunos identificados como vizinhos mais próximos (indivíduos que obtiveram um coeficiente de similaridade igual ou superior a um limiar pré-estabelecido). A equação 1 apresenta o cálculo da predição [Cazella and Correa and Reategui 2008].

$$p_{ai} = \bar{r}_a + \frac{\sum_{b=1}^n (r_{bi} - \bar{r}_b) * corr_{ab}}{\sum_{b=1}^n |corr_{ab}|} \quad (1)$$

Sendo que $corr_{ab}$ é a correlação do aluno alvo a com um determinado aluno b ; p_{ai} é a predição de um conteúdo i para um aluno alvo a ; \bar{r}_a é a média de todas as avaliações do aluno alvo a aos conteúdos que foram pontuados por todos os alunos similares; r_{bi} é a avaliação que o aluno ativo b atribuiu para o conteúdo i ; \bar{r}_b é a média de todas as avaliações do aluno b , em comum com o aluno a .

3.1.2 O Processo de Recomendação considerando Competências

Calculado o fator de predição de um objeto para um aluno, indicando o quanto este aluno apreciaria o referido item, é necessário agora aplicar as regras de competência. Estas têm por objetivo filtrar os objetos de aprendizagem de acordo com competências que precisam ser desenvolvidas. Através deste procedimento, são descartados objetos de aprendizagem que poderiam ter um bom fator de predição, mas não desenvolvem competências apontadas pelos professores como importantes em determinados momentos da disciplina.

Após a aplicação das regras de competência, o modelo verifica na base de dados se alguma predição de conteúdo foi feita e se esta recomendação está aguardando seu envio ao aluno. Assim que o sistema identifica que o aluno está conectado, a recomendação lhe é apresentada.

4. Modelo Proposto

O modelo proposto é apresentado na Figura 1. O modelo foi concebido como um serviço disponibilizado em um servidor de aplicação. Este serviço é chamado diariamente em um horário pré-determinado.

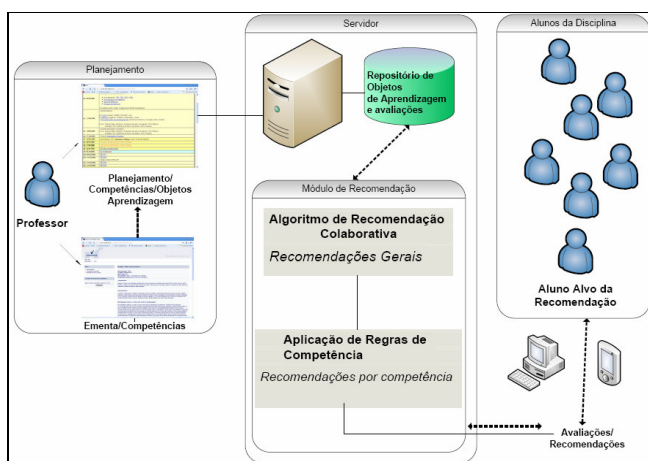


Figura 1 – Modelo Proposto

O modelo propõe a seguinte sequência de passos para seu funcionamento:

- 1) O Professor planeja as aulas com base nas competências descritas na ementa da disciplina. Este disponibiliza os objetos de aprendizagem a serem utilizados para desenvolver as respectivas competências, por exemplo, na quarta e quinta aula da disciplina de Banco de Dados o aluno deveria desenvolver a competência de “*Elaborar Projeções Aplicando Álgebra Relacional*” segundo o plano de aula, desta forma os objetos de aprendizagem que permitem desenvolver esta competência serão elencados pelo professor;
- 2) Na primeira execução do modelo é feito um cálculo geral, ou seja, o modelo calcula o coeficiente de similaridade (coeficiente de Pearson) entre todos os usuários cadastrados na base de dados que avaliaram conteúdos e depois realiza o cálculo da predição para todos os conteúdos cadastrados na base. Em novas interações apenas serão processados os novos usuários e conteúdos que entraram no sistema ou que já existiam, mas receberam novas avaliações;
- 3) Depois de executados os cálculos de coeficiente de similaridade e de predição (subseção 3.1.1), o modelo deve aplicar as regras da competência. Estas regras têm por objetivo filtrar os conteúdos recomendados pela predição de forma a permitir que o usuário possa desenvolver determinadas competências em um determinado tempo. Por exemplo, outros alunos similares ao aluno alvo avaliaram um objeto de aprendizagem relacionado à competência a ser desenvolvida na quarta e quinta aula, e o aluno alvo ainda não teve acesso a este objeto de aprendizagem que foi predito como de possível interesse, e filtrado pela competência de “*Elaborar Projeções Aplicando Álgebra*”

Relacional”. Como o aluno alvo não teve acesso a este objeto, e o mesmo foi predito como sendo de interesse do aluno, e o objeto atende a competência que está em desenvolvimento, o objeto deverá ser recomendado ao aluno.

4.1. Protótipo e Experimentos

A prototipação do modelo possibilitou a avaliação do mesmo. Alguns alunos convidados a participar dos experimentos avaliaram objetos de aprendizagem (neste caso artigos científicos) que lhe foram recomendados pelo sistema.

A escala adotada para avaliação dos objetos de aprendizagem foi uma escala *Likert* de 5 pontos, onde a opção “Não avaliado” é a opção padrão onde o usuário pode não querer avaliar o objeto naquele momento; neste caso, é adotado internamente o valor 0; opção “Péssimo”, equivalendo ao valor 1; opção “Ruim”, equivalendo ao valor 2; opção “Bom”, equivalendo ao valor 3; opção “Muito Bom”, equivalendo ao valor 4; opção “Excelente”, equivalendo ao valor 5. A ferramenta para avaliação dos objetos de aprendizagem foi desenvolvida como uma ferramenta Web que pode ser acessada por todo dispositivo que possua um *browser* e tenha acesso à Internet. A figura 2 apresenta as Telas do protótipo em PDA (*Personal Digital Assistant*).

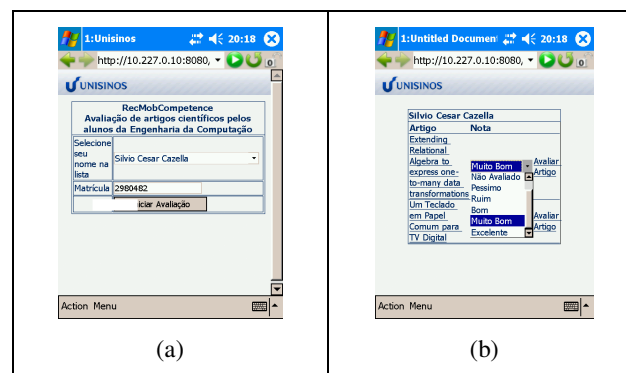


Figura 2 – (a) Tela de acesso ao protótipo em um dispositivo móvel; (b) Tela com opções para avaliação de artigos

Para o desenvolvimento deste protótipo foi utilizada a linguagem de programação Java, e a camada de persistência foi desenvolvida utilizando a API JDBC. A base de dados foi implementada utilizando MySQL5.

4.1.1 Método de Pesquisa

A avaliação do protótipo se deu através de dois experimentos com uma amostra por conveniência (não probabilística) de 10 alunos do final do curso de graduação de Engenharia da Computação da Universidade. Os objetos de aprendizagem utilizados para a recomendação foram artigos científicos selecionados por um professor especialista da área, e que tinham direta relação com as competências a serem desenvolvidas na disciplina de Banco de Dados.

Os experimentos realizados tiveram os seguintes objetivos: 1) Avaliar se as notas de predição calculadas pelo protótipo conseguiriam igualar-se ou aproximar-se da avaliação dos alunos utilizando-se a métrica de avaliação MAE (*Mean Absolute Error*) [Cazella and Correa and Reategui 2008]; 2) Avaliar a precisão nas recomendações dos objetos de aprendizagem através das métricas *Recall* (abrangência) e *Precision*

(precisão) [Cazella and Correa and Reategui 2008]. No contexto de sistemas de recomendação, diz-se que a precisão é a relação entre a nota dada pelo usuário a um conteúdo que lhe foi recomendado e a nota da predição do sistema. Assumiu-se que os artigos a serem recomendados aos usuários são apenas aqueles que possuem predição igual ou superior a 3 pontos, dentro de uma escala *Likert* de 5 pontos. Para avaliar o sistema foram aplicadas as métricas descritas a seguir.

4.1.2 Métricas de Avaliação

A métrica MAE (*Mean Absolute Error*) permite calcular o desvio absoluto médio entre as predições do sistema de recomendação e as avaliações reais feitas pelos alunos, e a diferença obtida é tomada como o erro da predição [Herlocker et al 2004]. Com esta métrica, é possível verificar qual o impacto da utilização das recomendações feitas pelo sistema no que se refere à margem de erro das recomendações calculadas. A equação (2) apresenta o cálculo do MAE, onde p_i constitui nos valores preditos pelo sistema, r_i constitui nos valores das avaliações dos usuários aos itens recomendados, e n refere-se ao número de itens considerados.

$$|\overline{E}| = \frac{\sum_{i=1}^n |p_i - r_i|}{n} \quad (2)$$

A métrica *Precision* é uma métrica muito utilizada em sistemas de recuperação de informação, e representa a relação entre o número de conteúdos relevantes sobre o total de conteúdos retornados. No contexto de sistemas de recomendação, se diz que *Precision* é a relação entre o número de conteúdos que o usuário considera relevante e o número de conteúdos recomendados. Por sua vez, a métrica *Recall* é uma medida do número de conteúdos recomendados, e *Precision* é a medida de quanto os conteúdos recomendados são relevantes ao usuário. *Recall* (Equação 3) e *Precision* (Equação 4) são definidas como [Cazella and Correa and Reategui 2008]:

$$Recall = \frac{|RA|}{R} \quad (3) \quad Precision = \frac{|RA|}{A} \quad (4)$$

Onde RA é número de conteúdos relevantes recomendados pelo sistema; R é número de conteúdos totais que deveriam ser recomendados; A é número de conteúdos recomendados pelo protótipo, levando-se em conta os positivos e os falsos positivos. Com estas métricas, foi possível verificar qual o impacto da utilização da competência em um determinado período de tempo no que se refere à precisão dos conteúdos recomendados.

4.2 Experimentos e Resultados

4.2.1 Primeiro Experimento: Avaliação de Artigos Pré-Selecionados

O primeiro experimento teve como objetivo selecionar uma base inicial de objetos de aprendizagem para a disciplina de Banco de Dados, objetos necessários para desenvolver as competências da disciplina. Foram selecionados 30 artigos científicos, os quais foram catalogados por competência pelo professor da disciplina. Desta forma buscou-se a criação de uma base com relação de cardinalidade de $1:N$, onde cada competência possuía N artigos científicos que possibilitassem o seu desenvolvimento

durante a disciplina. As competências foram distribuídas nos encontros conforme o plano de aula e os objetos de aprendizagem foram organizados conforme as competências que representavam. Estes artigos foram então avaliados pelos acadêmicos amostrados, com vistas a resolver a limitação denominada de *cold start* presente na técnica de Filtragem Colaborativa [Herlocker et al 2004].

Os alunos foram solicitados a avaliarem artigos que lhes foram atribuídos de forma randômica, usando para isso, a ferramenta de avaliação do protótipo (figura 2). Estes artigos foram distribuídos para os alunos, gerando assim uma matriz de avaliações iniciais “*artigo x usuário*”, totalizando 103 avaliações. Em média, foram atribuídos 10,3 artigos para avaliação por aluno e estas avaliações iniciais tratavam de auxiliar o protótipo na identificação das preferências/perfil de cada aluno. A partir das avaliações fornecidas, o sistema pôde calcular o coeficiente de similaridade entre os alunos, utilizando para isso o cálculo do coeficiente de Pearson (escala de -1 para fraca correlação, a 1 para forte correlação). Aplicando o cálculo do coeficiente de Pearson nesta amostra obteve-se os coeficientes de similaridade entre os alunos, onde por exemplo, o valor de correlação entre os alunos U4 e U6 foi de 1, o que demonstra uma forte correlação segundo o coeficiente de Pearson. O coeficiente de Pearson calculado entre os alunos U2 e U4 foi de -1, o que significa uma ausência total de similaridade entre esses usuários. Como resultado, obteve-se que 27,59% das correlações calculadas entre os alunos usando o coeficiente de Pearson foram consideradas fortes (estes alunos apresentavam “gostos” semelhantes pelos objetos avaliados), 20,69% foram consideradas fracas (estes alunos apresentavam “gostos” divergentes pelos objetos avaliados). Para 51,72% das correlações calculadas nada se pôde afirmar.

4.2.2 Segundo Experimento: Geração das Predições

No segundo experimento, foi executada a segunda rodada de avaliações de artigos científicos pelos acadêmicos após o sistema ter recomendado novos artigos a eles (com base nas avaliações fornecidas no primeiro experimento). Neste momento, os acadêmicos foram solicitados a avaliar os artigos gerados como recomendação do protótipo. O sistema recomendou apenas os artigos que obtiveram nota de predição igual ou superior a 3 dentro de uma escala *Likert* de 5 pontos. Após a execução do cálculo de correlação de similaridade e predição, foi aplicada a regra de competência na disciplina de Banco de Dados. Para conseguir analisar a questão de competência em um determinado período de tempo (um dos semestres do ano letivo, no caso do experimento), utilizou-se o plano de aula do professor da disciplina. Neste plano de aula existiam conteúdos pré-programados para serem ministrados em cada aula, considerando as competências que deveriam ser desenvolvidas em cada momento.

Como informado anteriormente, os artigos científicos foram catalogados por competência e estas estavam distribuídas no plano de aula por encontro. Desta forma, por exemplo, a aula referente à competência “*Elaborar Projeções Aplicando Álgebra Relacional*”, estava registrada no oitavo encontro da disciplina e se estenderia até o décimo encontro. Os alunos, durante este período, deveriam receber recomendações de objetos de aprendizagem apropriados para desenvolver esta competência.

A Tabela 2 apresenta o cálculo do MAE e a precisão obtida após o segundo experimento. Através da métrica MAE observou-se uma diferença média entre as predições feitas pelo protótipo e as avaliações feitas pelos alunos de um ponto (1 ponto). O grau de precisão atingida pelas predições do protótipo foi de 76%, o que foi

considerado satisfatório dentro da amostragem disponível. Na Tabela 2 pode-se observar que com a aplicação da Filtragem Colaborativa e do filtro da competência, foram geradas 16 recomendações para os alunos amostrados conforme os encontros planejados para as aulas. Todas essas recomendações referiam-se às competências a serem desenvolvidas pelos alunos nos encontros previstos para o mês de outubro de 2008. Deve-se observar que o aluno U4 não consta na Tabela 2 por não ter avaliado os artigos recomendados pelo sistema.

Tabela 2 – Resultado dos experimentos

Usuário	Artigo recomendado	Predição	Avaliação do usuário	MAE	Precisão
U1	19	4,54	5	0,46	90,80%
U1	22	3,35	4	0,65	83,75%
U1	23	3,62	4	0,38	90,50%
U2	20	4,04	5	0,96	80,80%
U3	20	3,29	4	0,71	82,25%
U3	22	3,92	4	0,08	98,00%
U3	23	4,37	5	0,63	87,40%
U5	19	4,53	3	1,53	66,23%
U5	22	3,67	3	0,67	81,74%
U6	19	5	2	3	40,00%
U7	19	3	1	2	33,33%
U7	22	3	2	1	66,67%
U8	20	5	4	1	80,00%
U9	19	5	3	2	60,00%
U10	20	3,5	3	0,5	85,71%
U10	23	4,5	4	0,5	88,89%
Media:				1,00	76,00%

A tabela 3 apresenta os resultados dos experimentos com relação à relevância das recomendações para os alunos.

Tabela 3 – Resultado dos experimentos

Usuário	Qtde. Artigo recomendado pela FC	Qtde. Artigo recomendado pela FC e competência	Qtde. Artigo relevantes recomendado pela FC e competência	Recall	Precision
U1	7	3	3	0,75	1,00
U2	7	1	1	0,25	1,00
U3	7	3	3	0,75	1,00
U5	4	2	2	0,50	1,00
U6	5	1	0	-	-
U7	3	2	0	-	-
U8	8	1	1	0,25	1,00
U9	7	1	1	0,25	1,00
U10	5	2	2	0,50	1,00
Total:	53	16	13		

Para 7 dos 10 alunos, é possível afirmar que o protótipo conseguiu recomendar de maneira bastante apropriada os artigos que eram relevantes para que o usuário desenvolvesse as competências no período estipulado (conforme o plano de aula), uma vez que o fator *Precision* chegou a 1 e o fator *Recall* ficou abaixo deste valor. Já os alunos U6 e U7 receberam, respectivamente, uma e duas recomendações cada um, recomendações baseadas em Filtragem Colaborativa e competências. Porém, as notas que estes usuários deram para as recomendações não foram satisfatórias para o cálculo da predição, que é de no mínimo 3. Logo, não foi possível afirmar nada sobre estes alunos em especial. Novamente, seriam necessárias avaliações complementares para se chegar a alguma conclusão com relação a estes alunos.

5. Conclusão

O principal objetivo desta pesquisa foi possibilitar a recomendação de objetos de aprendizagem aos alunos com o intuito de: (a) auxiliar os alunos a terem acesso a materiais educacionais relacionados ao desenvolvimento de competências específicas; (b) flexibilizar o processo de sugestão de materiais a serem consultados/utilizados pelos alunos, na medida em que os interesses de cada um passaram a ser considerados no

processo de recomendação. Ao dar suporte aos alunos em suas aprendizagens, o sistema computacional aqui proposto termina por apoiar também o trabalho do professor, sendo de responsabilidade deste a organização de materiais e situações de aprendizagem, propiciando uma melhor articulação entre saberes e competências. Neste sentido, o modelo proposto procura se alinhar a estes princípios, recomendando objetos de aprendizagem que melhor se adaptam aos interesses do aluno, mas respeitando competências que precisam ser desenvolvidas em determinado momento. Através dos experimentos realizados com uma turma de alunos da graduação em Engenharia da Computação, pôde-se verificar que o grau de precisão atingido pelas recomendações geradas pelo protótipo foi satisfatório. O grau de precisão de 76% evidenciou que o sistema conseguiu recomendar os objetos de aprendizagem que satisfariam os alunos para seus estudos, sem negligenciar as competências exigidas na ementa da disciplina durante o semestre. Conforme as métricas de avaliação *Recall* e *Precision* pode-se afirmar que o protótipo conseguiu fazer com que os alunos dentro do conjunto de objetos de aprendizagem disponíveis tivessem acesso exatamente àqueles que eram relevantes para a competência a ser desenvolvida no período.

Como trabalhos futuros destacam-se: testar o sistema com outros tipos de objetos de aprendizagem para verificar se o seu desempenho se mantém satisfatório; utilizar informações dos metadados dos objetos de aprendizagem para selecioná-los de acordo com necessidades específicas também relacionadas ao desenvolvimento de competências (ex.: nível de dificuldade, nível de interação, etc); incluir a relevância de opinião de um usuário para complementar o processo de recomendação; implementar a formação de comunidades virtuais entre os usuários que possuam um coeficiente de similaridade dentro da escala aceitável.

Referências

- Adomavicius, G. and Tuzhilin, A. (2005) "Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions". In *IEEE Transactions On Knowledge and Data Engineering*, vol. 17, no. 6, pages 734-749.
- Cazella, S.C. and Corrêa, I. and Reategui, E. (2008) "Um modelo para recomendação de conteúdos baseado em filtragem Colaborativa para dispositivos móveis". *Revista Novas Tecnologias na Educação*, v. 7, pages 12-22.
- Dutra, J. S. (2001) , *Gestão por Competências*. Editora Gente, São Paulo.
- Fleury, A. C. C. and Fleury, M. T. L. (2000) *Estratégias empresariais e formação de competências*. Atlas.
- Herlocker, J., Konstan, J., Terveen, L., Riedl, J. (2004) "Evaluating Collaborative Filtering Recommender Systems" In *ACM Transactions on Information Systems*, Vol. 22, No. 1, pages 5-53.
- Perrenoud, P. (1999) "Construir as competências desde a escola". Artmed, Porto Alegre.
- Sarwar, B. G., Karypis, G. , Konstan, J. , Riedl, J. (2000) "Analysis of recommender algorithms for ecommerce" In *ACM E-Commerce Conference* , Minneapolis, MN, pages 158-167, ACM Press.
- Schafer, J. B., Konstan, J., Riedl, J. (2001) "E-Commerce Recommendation Applications" In *Data Mining and Knowledge Discovery*, Hingham, MA,USA, Vol 5. Issue 5, Kluwer Academic Publishers.
- Shardanand, U. and Maes, P. (1995) "Social information filtering: Algorithms for automating "word of mouth"", In *Human Factors in Computing Systems*, Denver, Colorado, USA.
- Wiley, D. A. (2000) "Learning object design and sequencing theory". Tese de doutorado, Brigham Young University.
- Zarifian, P. (2002) "La politique de la compétence et l'appel aux connaissances à partir de la stratégie d'entreprise post-fordiste". Contribuição ao Colóquio de Nantes, 13 de dezembro 2002.<http://www.scoplepave.org/ledico/auteurs/zarifian%20competence%201.htm>. Agosto.